CH 2025-09-24

Errori di round-off.

- **Reali.**

Un numero "reale" è rappresentato in memoria da una stringa del tipo:

(1) $\alpha_0\ \alpha_1 \cdots \alpha_m\ \beta_1 \cdots \beta_s$

Fissata una base di rappresentazione $b \in \mathbb{N}$ (pari), le cifre della stringa sono così definite:

(2) $$\begin{cases} \alpha_0 \in \{+,-\} \\ \alpha_i, \beta_j \in \{0,1,\dots,b-1\}, & i=1,\dots,m \\ & j=1,\dots,s \\ \text{con } \alpha_1 \neq 0. \end{cases}$$

Con questa stringa si rappresenta il numero, in notazione scientifica,

(3) $$f \cdot b^{e-v},$$

dove, a meno del segno, specificato da α_0, f è la **mantissa**:

(4) $$f = \sum_{i=1}^{m} \alpha_i b^{1-i}$$

Ad esempio, se $b = 10$, $n = 4$,

$$\alpha_1 \alpha_2 \alpha_3 \alpha_4 = 3\ 4\ 0\ 7$$

descrive 3.407

L'esponente di b è dato da

$$e = \sum_{j=1}^{s} \beta_j b^{s-j}, \qquad (5)$$

a cui si sottrae lo "shift" ν che è fissato. Quest'ultimo è scelto in modo da poter rappresentare all'incirca lo stesso numero di esponenti negativi e positivi. Pertanto, poiché

$$0 \le e \le (b-1) \sum_{i=1}^{s} b^{s-i}$$

$$= (b-1)\,\frac{b^s - 1}{b-1} = b^s - 1.$$

Ne consegue che, essendo $b^s \gg 1$, allora $\nu \approx \frac{b^s}{2}$. (6)

Riguardo alla mantissa, abbiamo che

$$1 \leq s \leq \left((b-1).\underbrace{(b-1)\ldots(b-1)}_{m-1}\right)_b$$

$$= b(1-b^{-m}) < b$$

OSS:

1) I numeri della forma (1)-(6) sono in numero finito.

Definizione I numeri della forma (1)-(6) costituiscono, assieme allo ϕ, l'insieme dei numeri di macchina normalizzati, $\mathcal{M}$.

2) Dalla scelta (6) dello shift v, segue che $\mathcal{M}$ contiene (segno a parte) praticamente lo stesso numero di numeri di macchina in $[0,1[$ e in $(1,+\infty)$.

3) Il più piccolo numero di macchina positivo è:

$$r_1 = b^{-p};$$

Similmente, si vede che il più grande numero di macchina si ottiene quando $\alpha_i = (b-1)$, $i = 1, \dots, m$, e $\beta_j = (b-1)$, $j = 1, \dots, s$. Così facendo, si ottiene

$$r_2 = (1 - b^{-m})\, b^{b^s - p} \approx b^{b^s - p}.$$

Possiamo quindi concludere che

$$\mathcal{M} \subset [-r_2, -r_1] \cup \{0\} \cup [r_1, r_2] \equiv \mathcal{I}$$

L'insieme $\mathcal{I}$ rappresenta il sottoinsieme dei numeri reali che possiamo sperare di rappresentare in macchina.

Dobbiamo pertanto definire, essendo $\mathcal{I}$ un insieme denso e $\mathcal{M}$ un

insieme numerabile, una funzione,

$$fl : x \in \mathbb{I} \longrightarrow \tilde{x} \in \mathbb{M}.$$

fl è detta macchina "floating" e $\tilde{x} = fl(x)$ è il floating di x, che individua il numero di macchina che associamo a x.

Definizione Chiamiamo **errore di rappresentazione** la quantità

$$fl(x) - x.$$

Vediamo come si implementa la funzione fl. Per costruzione, vale:

- $fl(0) = 0$. [più in generale, se $x \in \mathbb{M}$, allora $fl(x) = x$].
- $x > 0$, $fl(-x) = -fl(x)$.

Pertanto è sufficiente dettagliare

l'implementazione di $fl(x)$, $x > 0$.

Per quanto esposto, se

$x \in I$, $x > 0$, allora

$$x = \alpha_1 . \alpha_2 \dots \alpha_m \alpha_{m+1} \alpha_{m+2} \dots \cdot b^{e-v}$$

A questo punto, esistono sostanzialmente 2 modi di implementare $fl(x)$:

- troncamento alla m-esima cifra
- arrotondamento alla m-esima cifra

Troncamento

$$fl(x) = \alpha_1 . \alpha_2 \dots \alpha_m \cdot b^{e-v},$$

quindi abbiamo troncato la mantissa di x alla m-esima cifra;

Arrotondamento

$$fl(x) = \alpha_1 . \alpha_2 \dots \alpha_{m-1} \tilde{\alpha}_m \, b^{e-v},$$

con

$$\tilde{\alpha}_m = \begin{cases} \alpha_m, & \text{se } \alpha_{m+1} < b/2, \\ \alpha_m + 1, & \text{se } \alpha_{m+1} \geq b/2. \end{cases}$$

Es:

$$x = (1.2345)_{10} \quad e \quad m = 3$$

$$\Rightarrow fl(x) = (1.234)_{10}, \text{ con il troncamento,}$$

$$e \quad fl(x) = (1.235)_{10}, \text{ con l'arrotondamento.}$$

Riguardo all'errore di rappresentazione, vale il seguente risultato.

Teorema 1 Per i numeri di $\mathbb{I}$ positivi, vale che l'errore relativo di rappresentazione,

$$\varepsilon_x = \frac{|fl(x) - x|}{x} \leq u = \begin{cases} b^{1-m}, & \text{se troncamento,} \\ \frac{1}{2} b^{1-m}, & \text{se arrotondamento.} \end{cases}$$

Def. u è detta precisione di macchina dell'aritmetica finita.

dim.

$$x = \alpha_1 . \alpha_2 \dots \alpha_m \alpha_{m+1} \alpha_{m+2} \dots \cdot b^{e-s}$$

$$fl(x) = \alpha_1 . \alpha_2 \dots \alpha_m \cdot b^{e-s}$$

$$\varepsilon_x = \frac{x - fl(x)}{x} = \frac{\overbrace{0.0\dots0}^{m}\, \alpha_{m+1} \dots \cdot b^{e-s}}{\alpha_1 . \alpha_2 \dots \cdot b^{e-s}}$$

$$= \frac{\alpha_{m+1} . \alpha_{m+2} \dots \cdot b^{-m}}{\alpha_1 . \alpha_2 \dots}$$

$$1 \leq \alpha_1 . \alpha_2 \dots$$

$$\leq \frac{\alpha_{m+1} . \alpha_{m+2} \dots}{1} \; b^{-m} = b^{1-m}$$

($\alpha_{m+1} \leq b$)

□

OSS Pertanto concludiamo che la precisione di macchina di un'aritmetica finita è una maggiorazione uniforme dell'errore relativo di rappresentazione.

Cosa succede a $fl(x)$ se $x \notin I$?

Nello specifico, se $x > 0$, cosa succede a $fl(x)$ se

$x > r_2$ oppure $0 < x < r_1$?

Se $x > r_2$, sostanzialmente

$fl(x) = +\infty$. (recovery standard)

Questa è "gestibile", usualmente, entro certi limiti (Es: $\frac{1}{+\infty} = 0$).

La condizione $x > r_2$ (o $x < -r_2$) è denominata **overflow**.

La condizione $0 < x < r_1$ è denominata **underflow**. Per questa sono previste sostanzialmente due tipi di recovery (alternative):

stop ϕ in cui $fl(x) = 0$.

gradual underflow: in questo caso, il numero di macchina viene denormalizzato, permettendo ad α di essere nullo. Chiaramente, questo va a discapito della accuratezza di rappresentazione (e.g. il Teorema 1 non è più valido).

In conclusione, per la funzione fl vale che:

$$fl(x) = \begin{cases} x, & x \in \mathcal{U} \\ -fl(-x), & \text{se } x < 0, \\ \text{underflow}, & \text{se } 0 < |x| < r_1, \\ \text{overflow}, & \text{se } |x| > r_2. \end{cases}$$